

↓ 1

$$X = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 3 & 3 & 0 & 0 \\ 4 & 4 & 0 & 0 \\ 0 & 0 & 4 & 4 \\ 0 & 0 & 5 & 5 \\ 0 & 0 & 2 & 2 \end{bmatrix} \begin{matrix} \leftarrow P_1 \\ \leftarrow P_2 \\ \leftarrow P_3 \\ \leftarrow P_4 \\ \leftarrow P_5 \\ \leftarrow P_6 \end{matrix} \left. \begin{matrix} \\ \\ \\ \\ \end{matrix} \right\} \begin{matrix} \text{Grupo 1} \\ \\ \\ \text{Grupo 2} \end{matrix}$$

- a) Implica el poder descubrir patrones presentes en los señales como en los pacientes que se pueden agrupar en una muestra y ahorrarse en analizar cada paciente, una forma de comprimir los datos.
- b) Dado que existe colinealidad entre sus variables, es evidente porque la columna 1 = columna 2 y la columna 3 = columna 4; por ende son redundantes estas señales.

c) $\sigma_1 = 7.35$, $\sigma_2 = 5.10$

σ_i^2

Varianza
componente 1

54.0225

Varianza
componente 2

26.01

→ Varianza Total = 80.0325

✓ Porcentaje de cada componente

$P_1 = \frac{54.0225}{80.0325} \times 100\%$

$P_2 = \frac{26.01}{80.0325} \times 100\%$

$P_1 = 67.5\%$

$P_2 = 32.5\%$

d) $X_{cucia} = [3 \ 3 \ 0 \ 0]$

→ Se asocia más al primer grupo de pacientes (1-3), debido a la coincidencia de datos existentes en las columnas 1 y 2; y ceros en las columnas 3 y 4 (no hay características).

e) Usualmente, el PCA es sensible a datos con una varianza muy grande, por ejemplo señales con rangos altos (Frec. cardíaca, presión arterial, SpO_2), por eso la estandarización regula la media a un 0 relativo y a rangos pequeños; y la varianza a 1.

Si se omite en un dataset biomédico real, los cambios se encontrarán en una escala grande donde hay oscilaciones y cambios; sin embargo, si se analiza un parámetro que tiene variaciones no tan alarmantes (ej: temperatura), se reconocerá que no existirá ningún cambio, en otras palabras, no se considera tiene información relevante, cuando realmente sí es útil.

↓

21

$$J = \sum_{k=1}^K \sum_{x_i \in C_k} \|x_i - \mu_k\|^2$$

a) Significa lograr que los clusters sean más compactos posible y garantiza que cada cluster tengan perfiles similares en sus elementos.

b) El centroide u_x representa el perfil clínico de un paciente promedio.

Como ejemplo, consideramos estos parámetros: Glucosa, IMC, Presión

$\Rightarrow$ Centroides u_1 : [Glucosa: 95, IMC: 23.5, Presión: 118]

Centroides u_2 : [Glucosa: 160, IMC: 31.2, Presión: 145]

u_1 es un paciente sano mientras u_2 es un paciente enfermo, en lo que se encuentre otro perfil cercano/parecido a u_2 , será clasificado como enfermo.

c) Por su algoritmo de optimización local que depende de la posición donde se crean los centroides, puesto que si se ubican en lugares poco representativos, el algoritmo se estanca en un mínimo local,

d) No garantiza el mínimo global. K-means busca la solución más cercana y eficiente según la ubicación inicial de los centroides; cuando dejan de moverse, llega a ser un mínimo local.

e) Es el número de veces donde los centroides tienen una posición inicial aleatoria, las repeticiones en donde una de ellas se genera en una zona favorable que encuentre un mínimo global y luego se descarte los demás intentos

f) Porque al compactar estos grupos, garantiza que los tumores reales sean muy similares al valor central. Permite facilitar a los especialistas en agrupar muchas ~~diagnósticos~~ ^{diagnósticos} individuales en pocos perfiles morfológicos

- g)
- Sensibilidad a los outliers, el algoritmo minimiza la suma de las distancias al cuadrado. Esto puede arrastrar al centroide lejos del núcleo real de los pacientes ante un outlier (uno alto, error, ruido) lo que deforma el perfil clínico promedio)
 - El hecho de definir manualmente el K ideal por medio de ~~asunción~~ ^{asunción} de rangos. Más que nada afecta en el estudio de subtipos de enfermedades puesto que ~~si no~~ ^{si} se configura en el múltiplo de los subtipos y se clasifican los clústeres, se pierde información importante y crucial.